Eficiência Defensiva — Especificação do Cálculo

SADA Scout · documento técnico para leitura e interpretação por humanos e por IA · gerado a partir do código em produção (`scripts/engine/positions.py`) · dados de exemplo: Série A 2026, pool de zagueiros

1. O que é

Eficiência Defensiva é uma métrica composta que resume, num único z-score, o balanço entre o que um defensor **produz** em ações defensivas e o que ele **custa** em duelos perdidos, faltas e erros capitais. Ela não mede volume bruto (isso fica nos cards "Duelos Defensivos" e "Ações Defensivas"); mede **saldo**: ações bem-sucedidas *menos* custos, tudo padronizado contra os colegas de posição na mesma liga e temporada.

O número é calculado **offline, em Python**, na geração dos dados do site, e gravado nos JSONs de perfil. O front-end nunca recalcula — só exibe e deriva produtos (percentil, nota, selo).

Quem recebe o card	Onde aparece	Onde é calculado
Zagueiros, laterais e meio-campistas. Extremos e atacantes não têm.	Seção "Defensivos" do dossiê do atleta; barra "Disciplina defensiva"; eixo do scatter; amostras da projeção; nota da seção.	`_def_efficiency_z_scores()` e `_def_efficiency_group_aspect()` em `scripts/engine/positions.py`

2. Pool de referência (em quem a régua é calibrada)

Todos os z-scores e percentis são relativos a um **pool de posição** (ex.: todos os zagueiros da Série A 2026) e a uma **amostra qualificada** dentro dele:

- **Critério de qualificação:** `%Minutos > 0.20` — o atleta precisa ter mais de 20% dos minutos do líder de minutos da liga. `%Minutos = minutos do atleta ÷ minutos do líder`.
- **Mínimo de amostra:** se menos de 8 atletas se qualificam, o pool inteiro vira referência (`MIN_REFERENCE_PLAYERS = 8`).
- **Efeito:** médias e desvios são estimados **só nos qualificados**, mas **todos** os jogadores recebem nota — quem tem poucos minutos é medido na régua dos titulares, sem influenciá-la.
- **Escopo:** o cálculo é refeito **separadamente por posição, por liga e por temporada**. Um z-score "+1,0" na Série A não é comparável a "+1,0" na Série C — são réguas diferentes.

Exemplo real: Série A 2026 tem 114 zagueiros no pool; 73 estão acima da linha de 20% dos minutos do líder e formam a amostra de calibração.

3. Dicionário das métricas fonte

Oito componentes por 90 minutos — quatro de **ação** e quatro de **custo**. Provedores: WYSCOUT SOFASCORE DERIVADO

3.1 Componentes de ação (quanto maior, melhor)

Componente	Fórmula / coluna	Fonte	O que mede
Duelos defensivos vencidos	`DuelosDef × %DuelosDefW` "Duelos defensivos/90" × "% ganhos"/100	DERIVADO de WYSCOUT	Volume de duelos defensivos (disputas por bola, divididas, carrinhos contestados) em que o atleta saiu vencedor, por 90 min.
Interceptações	`interception_won_p90` fallback: "Interseções/90"	SOFASCORE	Passes do adversário cortados por leitura/antecipação, por 90 min.

Rebatidas (cortes)	`total_clearance_p90` fallback: "Cortes/90"	SOFASCORE	Bolas afastadas da zona de perigo, por 90 min.
Chutes bloqueados	`outfielder_block_p90`	SOFASCORE	Finalizações adversárias bloqueadas pelo atleta, por 90 min.

3.2 Componentes de custo (quanto maior, pior)

Componente	Fórmula / coluna	Fonte	O que mede
Duelos defensivos perdidos	`DuelosDef × (1 − %DuelosDefW)`	DERIVADO de WYSCOUT	Volume de duelos defensivos perdidos, por 90 min.
Faltas cometidas	`Faltas/90`	WYSCOUT	Faltas cometidas por 90 min, **sem** correção de contexto (ver §8).
Erro que leva a chute	`error_lead_to_a_shot_p90`	SOFASCORE	Erros individuais que resultaram em finalização adversária, por 90 min.
Erro que leva a gol	`error_lead_to_a_goal_p90`	SOFASCORE	Erros individuais que resultaram em gol adversário, por 90 min.

Observação: as quatro ações também alimentam, como percentis de volume individuais, o card irmão "Ações Defensivas". Na Eficiência elas entram padronizadas e combinadas com o custo.

4. O algoritmo, passo a passo

```
Passo 1 — z-score de cada componente (contra a amostra qualificada):
  z_i = (x_i − μ_ref,i) / σ_ref,i      se σ ≈ 0 → z = 0

Passo 2 — médias simples (peso igual) dos dois blocos:
  action_z = (z_duelos_venc + z_intercept + z_rebatidas + z_bloqueios) / 4
  cost_z   = (z_duelos_perd + z_faltas + z_erro_chute + z_erro_gol) / 4

Passo 3 — saldo:
  raw = action_z − cost_z

Passo 4 — re-padronização do saldo (segunda camada, contra a amostra qualificada):
  z_final = (raw − μ_ref(raw)) / σ_ref(raw)

Passo 5 — percentil:
  percentil = posto de z_final na escala da amostra qualificada, 0–100 (valores fora da amostra
são fixados nos extremos)
```

O resultado é uma **"padronização de padronizações"**: primeiro cada métrica vira desvios-padrão da média da posição (o que torna comparáveis métricas com escalas muito diferentes — rebatidas ~5/90 vs. erros ~0,05/90); depois o saldo ações−custos é re-padronizado para ter média 0 e desvio 1 no pool. **Interpretação:** z = +1,0 significa "um desvio-padrão acima do zagueiro típico da liga no saldo defesa−custo".

Por que média simples e não soma? A divisão por 4 mantém action_z e cost_z na mesma escala de um z-score, então a diferença entre eles tem interpretação direta.

5. Exemplo numérico completo (dados reais — Série A 2026, zagueiros)

Momentos da amostra qualificada (73 zagueiros):

Componente	μ_ref	σ_ref
Duelos def. vencidos /90	2,539	0,686
Interceptações /90	1,065	0,429
Rebatidas /90	5,242	1,424
Chutes bloqueados /90	0,800	0,392
Duelos def. perdidos /90	1,635	0,496
Faltas /90	0,896	0,348
Erro p/ chute /90	0,055	0,063
Erro p/ gol /90	0,018	0,042
raw (saldo)	≈ 0	0,729

5.1 Jonathan (Cruzeiro) — 1.816 min, qualificado, topo da escala

Bloco	Componente	Valor /90	z_i = (x−μ)/σ
Ação	Duelos vencidos	3,219	+0,990
	Interceptações	2,573	+3,521
	Rebatidas	5,576	+0,234
	Bloqueios	0,643	−0,399
Custo	Duelos perdidos	1,881	+0,496
	Faltas	0,940	+0,127
	Erro p/ chute	0,000	−0,863
	Erro p/ gol	0,000	−0,430

```
action_z = (0,990 + 3,521 + 0,234 − 0,399) / 4 = +1,086
cost_z   = (0,496 + 0,127 − 0,863 − 0,430) / 4 = −0,167
raw      = 1,086 − (−0,167) = +1,254
z_final  = (1,254 − 0) / 0,729 = +1,72 → exibido como "+1,7"
percentil = 100 (maior z da escala qualificada) · erros totais = 0 → pct_erros = 100
```

Leitura: zagueiro elite — produz acima da média (destaque: +3,5σ em interceptações) e custa abaixo dela. Selo **ouro** (ambos percentis > 90).

5.2 Luan Peres (Santos) — 2.119 min, qualificado, perfil mediano

```
action_z = +0,199  ·  cost_z = +0,256  ·  raw = −0,057
z_final = −0,057 / 0,729 ≈ −0,08 → percentil 43 · erros totais = 2 → pct_erros = 33
```

Leitura: saldo praticamente neutro; os 2 erros capitais na temporada derrubam o percentil de erros para 33 — e como o selo exige **os dois** percentis acima de 50, o card fica sem medalha mesmo com z mediano.

5.3 Casos-limite (o que a métrica faz sem tratamento de amostra)

Jogador	Min	Qualificado?	z_final	Percentil	Por quê
Igor Rabello (Fluminense)	190	não	+4,88	100	Amostra mínima com taxas irreais: 6,2 duelos vencidos/90 (z +5,3), 2,2 bloqueios/90 (z +3,6), 0 faltas (z −2,6 no custo). z extrapola a escala → fixado em 100.
Lucas Monzón (Botafogo)	527	não	−5,44	0	1 erro p/ chute em 527 min (0,19/90 vs σ 0,063) = z **+14,96** naquele componente → cost_z +4,0 afunda o saldo inteiro.

Leitura obrigatória: não há encolhimento por tamanho de amostra no z (o peso `_def_eff_sample_weight` existe no código mas **não é aplicado**). Extremos como ±5σ devem ser lidos sempre junto com os minutos — é ruído de amostra pequena, não certeza de nível.

6. Produtos derivados no site

Onde	Como usa o valor
Card "Eficiência Defensiva" (dossiê)	Expansível com 2 linhas: "Erros Totais" (contagem da temporada, percentil invertido — menos erros = percentil maior, esmaecida) e "Eficiência Defensiva" (o z com sinal, ex.: "+1,7"). Nota do card: faixas do percentil — A≥85, B+≥75, B≥65, B−≥55, C+≥45, C≥35, C−≥25, D<25.
Selo de medalha	Par `[pct_erros_invertido, pct_eficiência]`: exige **ambos > 50**; o nível sai do pior dos dois — >90 ouro, >75 prata, >50 bronze.
Nota da seção "Defensivos"	O bloco vale `0,4 × pct_erros + 0,6 × pct_eficiência` e entra na média da seção junto com "Duelos Defensivos" e "Ações Defensivas".
Barra "Disciplina defensiva"	O percentil do card é o de eficiência, mas a posição do ponto na barra é o percentil de `Faltas/90`.
Rating do zagueiro	O percentil é 1 das 5 métricas **core** do índice de zagueiro (peso cheio). Para laterais/MEIs aparece no card e na seção, mas não no rating composto.
Scatter	O eixo "Eficiência Defensiva" plota o **z bruto**, não o percentil.
Projeção de minutos	Vira 2 amostras: "Erros Totais" como taxa adversa (contagem ÷ noventas) e o z como amostra com sinal — afetam a projeção.
Similares	**Excluída** de propósito — z-score não é feature por-90 e não pode ser re-normalizado entre pools.

7. Convenções e comportamentos de borda

- **Sinal:** positivo = melhor que a média da posição. O display usa sempre sinal explícito ("+0,6", "−1,2").
- **Percentil é da escala qualificada:** valores fora da amostra (não-qualificados) são fixados em 0/100 — nunca acima de 100 nem abaixo de 0.
- **Distribuição achatada:** se algum componente tiver σ ≈ 0 no pool (ex.: liga sem dados SofaScore → erros todos zerados), seu z é 0 para todos — o componente simplesmente sai da conta, não quebra.
- **SofaScore ausente:** interceptações/rebatidas caem nas colunas Wyscout equivalentes; erros e bloqueios vão a 0 → o custo fica subestimado e a métrica pende para "volume defensivo".
- **Idempotentemente relativo:** a métrica é puramente comparativa — não existe "eficiência absoluta". O mesmo desempenho rende z diferente em pools diferentes.

8. Limitações conhecidas (para interpretação honesta)

- **Sem encolhimento bayesiano:** minutos baixos não puxam o z para a média (a função de peso existe, mas está desativada — código morto).
- **Faltas sem ajuste de contexto:** a versão anterior descontava duelos perdidos sobrepostos (β=0,45); a atual conta `Faltas/90` cheio — pune duplamente quem falta em duelo.
- **Pesos iguais:** bloqueios contam tanto quanto duelos vencidos; erro para gol conta tanto quanto falta (na média dos z's — embora sua variância baixa limite o impacto típico, um evento raro gera z enorme, cf. Monzón).
- **Dupla contagem parcial:** ações bem-sucedidas aparecem também nos cards de volume da mesma seção — a nota da seção não é independente entre blocos.
- **_custo_def_ajustado legado:** a razão custo÷ações antiga ainda é computada (`_custo_def_raw`) mas nada a consome.

9. Pseudocódigo canônico

```
# por posição, por liga, por temporada
qualificados = pool[%Minutos > 0.20]            # ≥ 8, senão pool inteiro
μ_ref, σ_ref = momentos(qualificados)            # por componente

para cada jogador:
    z[i]        = (x[i] − μ_ref[i]) / σ_ref[i]   # i ∈ 8 componentes; σ≈0 → 0
    action_z    = média(z[duelos_venc, intercept, rebatidas, bloqueios])
    cost_z      = média(z[duelos_perd, faltas, erro_chute, erro_gol])
    raw         = action_z − cost_z
    z_final     = (raw − μ_ref(raw)) / σ_ref(raw)
    percentil   = posto(z_final) na escala dos qualificados, fixado em [0,100]
    erros_pct   = percentil_invertido(erros_totais_temporada)
    selo        = ouro se min(erros_pct, percentil)>90; prata >75; bronze >50; senão nenhum
```

10. Mapa do código

Responsabilidade	Arquivo : função
Núcleo (z de z's)	`scripts/engine/positions.py` : `_def_efficiency_z_scores` (~L1032)
Pool de referência	`scripts/engine/pool_reference.py` : `reference_pool`, `distribution`
z-score de componente	`positions.py` : `_pool_z` (L1021) · `normalize.py` : `percentile_rank` (L61)
Colunas fonte	`measures.py` : `compute_base_measures` (`DuelosDef`, `%DuelosDefW`, `%Minutos`) · `positions.py` : `_ss_inter_col`, `_ss_clearance_col`, `_num_col`
Card no JSON	`positions.py` : `_def_efficiency_group_aspect` (~L1397), emitido p/ zag/lat/mei (L1911)
Selo / nota / seção	`lib/aspectBadges.ts` : `resolveAspectBadge` · `lib/sectionGrades.ts` : `defEfficiencyGroupScore` · `lib/aspectGrades.ts`
Outros consumidores	`lib/scatterAxis.ts` (z bruto) · `lib/minuteProjection.ts` (amostras) · `lib/crossLeagueSimilarity.ts` (excluída)

Valores das tabelas deste documento reproduzidos do pipeline real (Série A 2026, Wyscout + SofaScore). Nomes de colunas e constantes conforme o código na data de geração.