Eficiência Defensiva — Especificação do Cálculo

SADA Scout · documento técnico para leitura e interpretação por humanos e por IA · gerado a partir do código em produção (`scripts/engine/positions.py`) · dados de exemplo: Série A 2026, pool de zagueiros

1. O que é

Eficiência Defensiva é uma métrica composta que resume, num único z-score, o balanço entre o que um defensor **produz** em ações defensivas e o que ele **custa** em duelos perdidos, faltas e erros capitais. Ela não mede volume bruto (isso fica nos cards "Duelos Defensivos" e "Ações Defensivas"); mede **saldo**: ações bem-sucedidas *menos* custos, tudo padronizado contra os colegas de posição na mesma liga e temporada.

O número é calculado **offline, em Python**, na geração dos dados do site, e gravado nos JSONs de perfil. O front-end nunca recalcula — só exibe e deriva produtos (percentil, nota, selo).

Quem recebe o card	Onde aparece	Onde é calculado
Zagueiros, laterais e meio-campistas. Extremos e atacantes não têm.	Seção "Defensivos" do dossiê do atleta; barra "Disciplina defensiva"; eixo do scatter; amostras da projeção; nota da seção.	`_def_efficiency_z_scores()` e `_def_efficiency_group_aspect()` em `scripts/engine/positions.py`

2. Pool de referência (em quem a régua é calibrada)

Todos os z-scores e percentis são relativos a um **pool de posição** (ex.: todos os zagueiros da Série A 2026) e a uma **amostra qualificada** dentro dele:

- **Critério de qualificação:** `%Minutos > 0.20` **e** `Minutos ≥ 450` — mais de 20% dos minutos do líder **e** um piso absoluto, para que um líder de minutagem atípica não qualifique amostras mínimas. `%Minutos = minutos do atleta ÷ minutos do líder`.
- **Mínimo de amostra:** se o piso de 450 min deixar menos de 8 qualificados, volta-se à regra só de 20%; se ainda assim forem menos de 8, o pool inteiro vira referência.
- **Efeito:** médias e desvios são estimados **só nos qualificados**, mas **todos** os jogadores recebem nota — quem tem poucos minutos é medido na régua dos titulares, sem influenciá-la.
- **Escopo:** o cálculo é refeito **separadamente por posição, por liga e por temporada**. Um z-score "+1,0" na Série A não é comparável a "+1,0" na Série C — são réguas diferentes.

Exemplo real: Série A 2026 tem 114 zagueiros no pool; 73 estão acima da linha de 20% dos minutos do líder e formam a amostra de calibração.

3. Dicionário das métricas fonte

Seis componentes por 90 minutos — quatro de **ação** e dois de **custo** — todos passados por **encolhimento bayesiano** antes do z-score (ver §4). Provedores: WYSCOUT SOFASCORE DERIVADO

3.1 Componentes de ação (quanto maior, melhor)

Componente	Fórmula / coluna	Fonte	O que mede
Saldo de duelos defensivos	`D_adj × (2·p_adj − 1)` D = "Duelos defensivos/90"; p = "% ganhos"/100; volume e % encolhidos separadamente	DERIVADO de WYSCOUT	Duelos vencidos **menos** perdidos, por 90 min. Substitui os antigos "vencidos" (ação) + "perdidos" (custo), que contavam o mesmo evento duas vezes.

Interceptações	`interception_won_p90` fallback: "Interseções/90"	SOFASCORE	Passes do adversário cortados por leitura/antecipação, por 90 min.
Rebatidas (cortes)	`total_clearance_p90` fallback: "Cortes/90"	SOFASCORE	Bolas afastadas da zona de perigo, por 90 min.
Chutes bloqueados	`outfielder_block_p90`	SOFASCORE	Finalizações adversárias bloqueadas pelo atleta, por 90 min.

3.2 Componentes de custo (quanto maior, pior)

Componente	Fórmula / coluna	Fonte	O que mede
Faltas cometidas	`Faltas/90`	WYSCOUT	Faltas cometidas por 90 min.
Erros capitais	`2,5 × erro p/ chute + 10 × erro p/ gol` error_lead_to_a_shot_p90, error_lead_to_a_goal_p90; gol vale 4× chute	SOFASCORE	Eventos raros fundidos num único componente ponderado — antes eram duas colunas quase constantes pesando 50% do custo.

Observação: as ações de volume (duelos vencidos, interceptações, rebatidas, bloqueios) também alimentam o card irmão "Ações Defensivas" como percentis individuais **não encolhidos** — lá é cartão de volume, não de eficiência.

4. O algoritmo, passo a passo

```
Passo 1 — encolhimento bayesiano de cada taxa (contra ruído de amostra pequena):
  contagens (interceptações, rebatidas, bloqueios, faltas, erros capitais):
    r_adj = (eventos + α·μ_ref) / (noventas + α)    Gamma–Poisson
  α (força do prior, em noventas) vem do método dos momentos na amostra
  qualificada: α = μ / (var_observada − μ·E[1/n]), limitado a [2, 90].

  duelos — duas peças encolhidas separadamente:
    volume D/90 → mesmo Gamma–Poisson;
    % vitória p → Beta-Binomial: p_adj = (vencidos + κ·p_ref)/(duelos + κ),
    κ = prior em duelos estimado por momentos, limitado a [2, 120];
    componente final = saldo líquido = D_adj × (2·p_adj − 1) /90.

Passo 2 — z-score de cada componente encolhido (contra a amostra qualificada),
  winsorizado em ±3 — um evento raro não carrega a métrica sozinho:
  z_i = clip((r_adj,i − μ_ref,i) / σ_ref,i, −3, +3)

Passo 3 — médias simples dos blocos, cada bloco re-padronizado:
  action_z = média(z_saldo_duelos, z_intercept, z_rebatidas, z_bloqueios)
  cost_z   = média(z_faltas, z_erros_capitais)
  a* = z(action_z)  ·  c* = z(cost_z)    blocos com variâncias diferentes não se dominam

Passo 4 — saldo e padronização final:
  z_final = z( a* − c* ) = (raw − μ_ref(raw)) / σ_ref(raw)

Passo 5 — percentil: posto de z_final na escala da amostra qualificada, 0–100
  (valores fora da amostra fixados nos extremos)
```

Por que encolher antes do z? Com 190 minutos, taxas por 90 são dominadas por ruído Poisson. O encolhimento puxa cada taxa para a média da posição proporcionalmente à falta de evidência — quem tem 2.000 min quase não muda; quem tem 190 min volta para perto da média, em vez de gerar z de ±5σ.

Por que re-padronizar blocos separadamente? σ(action_z) e σ(cost_z) não são iguais — padronizar cada um dá ao saldo pesos implícitos iguais entre os blocos (o saldo final é padronizado mais uma vez para ter σ = 1).

5. Exemplo numérico completo (dados reais — Série A 2026, zagueiros)

Força do prior estimada por componente (α em noventas) e taxa média da amostra qualificada (73 zagueiros):

Componente	μ_ref /90	α (noventas)	Leitura
Interceptações	1,081	9,8	α ≈ 3–14 noventas: um jogador com ~300 min carrega ~25% da amostra dele no estimador; com 2.000 min, ~70%.
Rebatidas	5,371	3,2	
Chutes bloqueados	0,796	8,0	
Faltas	0,886	14,4	
Erros capitais (eq. chute)	0,297	1,7	
Volume de duelos	4,148	6,1	+ κ da % de vitória (Beta–Binomial)

5.1 Jonathan (Cruzeiro) — 1.816 min, qualificado, topo da escala

```
a* (bloco ação, re-padronizado) = +1,84 · c* (bloco custo) = −0,41
raw = 1,84 − (−0,41) = +2,24 → z_final = +2,24 / 1,35 = +1,66 → "+1,7" · percentil 98,6
erros totais = 0 → pct_erros = 100 → selo ouro
```

Leitura: zagueiro elite — destaque +3,0σ em interceptações (winsorizado de +3,5) e custo abaixo da média.

5.2 Luan Peres (Santos) — 2.119 min, qualificado, mediano

```
a* = +0,65 · c* = +0,99 · raw = −0,34 → z_final = −0,25 → percentil 32 · erros totais = 2 → pct_erros = 33
```

Leitura: saldo levemente abaixo da média, penalizado por 2 erros capitais — sem selo (pct_erros ≤ 50).

5.3 O efeito do encolhimento — antes × depois

Jogador	Min	z antigo	z novo	Por quê
Igor Rabello (Fluminense)	190	+4,88	+1,78	Taxas encolhidas à média: 6,2 duelos vencidos/90 viram saldo 1,34 (z +1,6); 0 faltas param de zerar o custo. Ainda é bom — mas não mais um outlier impossível.
Lucas Monzón (Botafogo)	527	−5,44	−1,69	Erros capitais encolhidos + z winsorizado em +3 (era +15). 6 erros p/ chute em 527 min continuam pesando — é ruim de verdade, não catástrofe estatística.
Jonathan (Cruzeiro)	1.816	+1,72	+1,66	Starter: quase nada muda — como deve ser.

Efeito líquido: o range do pool saiu de [−5,4 ; +4,9] para [−3,1 ; +2,2]. Extremos agora refletem evidência, não minutagem.

6. Produtos derivados no site

Onde	Como usa o valor

Card "Eficiência Defensiva" (dossiê)	Expansível com 2 linhas: "Erros Totais" (contagem da temporada, percentil invertido — menos erros = percentil maior, esmaecida) e "Eficiência Defensiva" (o z com sinal, ex.: "+1,7"). Nota do card: faixas do percentil — A≥85, B+≥75, B≥65, B−≥55, C+≥45, C≥35, C−≥25, D<25.
Selo de medalha	Par `[pct_erros_invertido, pct_eficiência]`: exige **ambos > 50**; o nível sai do pior dos dois — >90 ouro, >75 prata, >50 bronze.
Nota da seção "Defensivos"	O bloco vale `0,4 × pct_erros + 0,6 × pct_eficiência` e entra na média da seção junto com "Duelos Defensivos" e "Ações Defensivas".
Barra "Disciplina defensiva"	O percentil do card é o de eficiência, mas a posição do ponto na barra é o percentil de `Faltas/90`.
Rating do zagueiro	O percentil é 1 das 5 métricas **core** do índice de zagueiro (peso cheio). Para laterais/MEIs aparece no card e na seção, mas não no rating composto.
Scatter	O eixo "Eficiência Defensiva" plota o **z bruto**, não o percentil.
Projeção de minutos	Vira 2 amostras: "Erros Totais" como taxa adversa (contagem ÷ noventas) e o z como amostra com sinal — afetam a projeção.
Similares	**Excluída** de propósito — z-score não é feature por-90 e não pode ser re-normalizado entre pools.

7. Convenções e comportamentos de borda

- **Sinal:** positivo = melhor que a média da posição. O display usa sempre sinal explícito ("+0,6", "−1,2").
- **Percentil é da escala qualificada:** valores fora da amostra são fixados em 0/100 — mas agora o z encolhido torna raros os extremos artificiais.
- **Distribuição achatada:** σ ≈ 0 num componente → z = 0 para todos — o componente sai da conta sem quebrar.
- **SofaScore ausente:** interceptações/rebatidas caem nas colunas Wyscout; erros e bloqueios vão a 0 → custo subestimado.
- **Puramente relativo:** não existe "eficiência absoluta" — o mesmo desempenho rende z diferente em pools diferentes.
- **Encolhimento:** quem tem poucos minutos converge para a média da posição — o z dele carrega a incerteza, e a leitura deve ser "provavelmente mediano", não "elite/horrível".

8. Limitações conhecidas (para interpretação honesta)

- **Sem ajuste de contexto de equipe:** zagueiros de times reativos acumulam rebatidas/bloqueios; não há posse de equipe nos dados para ponderar. É a limitação mais relevante que resta.
- **Pesos iguais dentro dos blocos:** matriz de correlação dos componentes não mostra pares >0,6 (máx 0,34 em rebatidas×bloqueios), então a média simples é defensável — mas não há ponderação por "valor" (xG evitado/cedido).
- **Sem prior do próprio jogador:** o prior é a média da posição, não o histórico individual de temporadas anteriores (melhoria futura possível com os dados cross-season já existentes).
- **Validação externa pendente:** falta split-half (dados agregados por temporada, sem por-partida) e validação preditiva contra resultado de equipe (xGA).
- **Dupla contagem parcial com a seção:** ações bem-sucedidas aparecem também nos cards de volume — a nota da seção não é independente entre blocos.

9. Pseudocódigo canônico

```
# por posição, por liga, por temporada
qualificados = pool[%Minutos > 0.20 e Minutos ≥ 450]   # ≥ 8; senão só %Minutos; senão pool

para cada componente de contagem c (interceptações, rebatidas, bloqueios,
                                    faltas, erros_capitais, volume_duelos):
    μ_c = Σ eventos / Σ noventas   # nos qualificados
    α_c = μ_c / (var_obs − μ_c·E[1/n])            # momentos; clip [2, 90]
    r_adj[c] = (eventos + α_c·μ_c) / (noventas + α_c)

# % de vitória em duelos — Beta-Binomial
p0 = Σ vencidos / Σ duelos                         # qualificados
κ  = p0(1−p0)/var_verd − 1                         # momentos; clip [2, 120]
p_adj = (vencidos + κ·p0) / (duelos + κ)
saldo_duelos = r_adj[vol_duelos] × (2·p_adj − 1)

para cada jogador:
    z[i]      = clip((r_adj[i] − μ_ref,i)/σ_ref,i, −3, +3)
    a*        = z( média(z[saldo_duelos, intercept, rebatidas, bloqueios]) )
    c*        = z( média(z[faltas, erros_capitais]) )
    z_final   = z( a* − c* )
    percentil = posto(z_final) na escala dos qualificados, fixado em [0,100]
    erros_pct = percentil_invertido(erros_totais_temporada)
    selo      = ouro se min(erros_pct, percentil)>90; prata >75; bronze >50
```

10. Mapa do código

Responsabilidade	Arquivo : função
Núcleo (encolhimento + z de z's)	`scripts/engine/positions.py` : `_def_efficiency_z_scores`, `_shrink_count_rate`, `_duelos_net_p90`, `_capital_errors_p90`
Pool de referência	`scripts/engine/pool_reference.py` : `reference_pool`, `distribution`
z-score de componente	`positions.py` : `_pool_z` (L1021) · `normalize.py` : `percentile_rank` (L61)
Colunas fonte	`measures.py` : `compute_base_measures` (`DuelosDef`, `%DuelosDefW`, `%Minutos`) · `positions.py` : `_ss_inter_col`, `_ss_clearance_col`, `_num_col`
Card no JSON	`positions.py` : `_def_efficiency_group_aspect` (~L1397), emitido p/ zag/lat/mei (L1911)
Selo / nota / seção	`lib/aspectBadges.ts` : `resolveAspectBadge` · `lib/sectionGrades.ts` : `defEfficiencyGroupScore` · `lib/aspectGrades.ts`
Outros consumidores	`lib/scatterAxis.ts` (z bruto) · `lib/minuteProjection.ts` (amostras) · `lib/crossLeagueSimilarity.ts` (excluída)

Valores das tabelas deste documento reproduzidos do pipeline real (Série A 2026, Wyscout + SofaScore). Nomes de colunas e constantes conforme o código na data de geração.